

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN MÔN HỌC
CS221 — Xử lý ngôn ngữ tự nhiên

So sánh tóm tắt rút trích và tóm lược trên tin tức tiếng Việt

A comparative study of extractive and abstractive summarization on Vietnews

Lead-3 · TextRank · ViT5 (checkpoint VietAI, không fine-tune)
100 bài test đầu · ROUGE-1/2/L · đọc tay 20 bài

Nhóm 14

Nguyễn Trí Toàn — 26410135
Nguyễn Văn Thái — 26410108
Đỗ Quốc Hoàng — 26410043

GitHub: github.com/hoangdq08/vietnews-summarization-extractive-abstractive

1. Tóm tắt

Báo cáo so sánh ba hệ tóm tắt tin tức tiếng Việt trên 100 bài đầu của tập test Vietnews (test_tokenized): Lead-3, TextRank, và checkpoint [VietAI/vit5-base-vietnews-summarization](#). Nhóm không fine-tune ViT5. Độ đo là ROUGE-1/2/L (F1) sau khi thay dấu gạch dưới bằng khoảng trắng trên cả bản tóm tắt và gold. ViT5 đạt ROUGE cao hơn một chút ($R-1 = 0,2664$) so với Lead-3 (0,2507) và TextRank (0,2428). Đọc tay 20 bài cho thấy ViT5 vẫn sai tên, đảo polarity và bịa chi tiết; Lead-3 ít bịa nhưng hay lệch gold.

2. Đặt vấn đề

Tin điện tử dài. Người đọc và tòa soạn cần bản ngắn. Máy làm theo hai hướng: rút trích (chọn câu có sẵn) và tóm lược (sinh câu mới). Câu hỏi nghiên cứu: trên cùng tập test tiếng Việt, ba hệ khác nhau thế nào về ROUGE, và khi đọc tay thì mỗi hệ sai kiểu gì?

Phạm vi cố ý không làm: fine-tune lại ViT5 trên Vietnews (trùng miền pretrain); tóm tắt đa văn bản BERT+K-Means (trùng bài giảng 8); crawl dữ liệu mới.

3. Bài toán

Input. Thân bài tiếng Việt đã tách từ (dấu “_”).

Output. Bản tóm tắt ngắn: Lead-3 và TextRank lấy 3 câu; ViT5 sinh văn bản.

Gold. Trường abstract trong file Vietnews (tách khỏi thân bằng dòng trống).

Độ đo. ROUGE-1, ROUGE-2, ROUGE-L (F1), cùng 100 id.

4. Dữ liệu

Nguồn: <https://github.com/ThanhChinhBK/vietnews>, thư mục data/test_tokenized. Mỗi file: tiêu đề, abstract, thân bài. Nhóm lấy 100 file đầu theo tên (000001.txt.seg ... 000100.txt.seg), danh sách trong data/test_ids.txt. Không tự xáo train/test. Không gọi lại underthesea trên gold — corpus đã tách từ.

5. Phương pháp

5.1. Lead-3

Ba câu đầu của thân bài. Baseline phổ biến cho tin tức (ý chính thường nằm ở đầu). Không học.

5.2. TextRank

Biểu diễn câu bằng TF-IDF (sklearn), ma trận cosine, PageRank 40 vòng, hệ số 0,85. Lấy 3 câu điểm cao, sắp lại theo thứ tự xuất hiện trong bài.

5.3. ViT5

Checkpoint VietAI/vit5-base-vietnews-summarization (Phan et al., 2022). Theo model card: không prefix vietnews:, thêm </s> vào cuối input, generate max_length=256. Chạy inference trên Kaggle (2× Tesla T4, một GPU cuda:0). Phiên transformers 5 trên Kaggle lỗi Unigram (KeyError: 0); nhóm gỡ bản 5, cài transformers==4.44.2 và T5Tokenizer. Nhóm không fine-tune.

5.4. ROUGE

Thư viện rouge-score, F1, không stemmer. Tokenizer: thay “_” bằng space rồi split khoảng trắng trên cả pred và ref. Lý do: gold và extractive giữ cá_nhân; ViT5 sinh lẫn “cá nhân”. Giữ dấu “_” sẽ trừ oan ViT5. Số trong báo cáo là bản đã chuẩn hoá. Không đối sánh với bảng paper (tokenizer paper không kiểm được từ model card).

6. Kết quả thực nghiệm

Bảng 1. ROUGE F1 trên 100 bài test đầu (cùng id).

Hệ	ROUGE-1	ROUGE-2	ROUGE-L
Lead-3	0,2507	0,1296	0,1841
TextRank	0,2428	0,1100	0,1730
ViT5	0,2664	0,1341	0,2084

ViT5 cao hơn một chút trên tập này. Lead-3 $\geq$ TextRank. Lead-3 không thấp hơn TextRank là hợp lý với tin tức: gold gần sapo, trong khi TextRank có thể nhảy vào đoạn giữa bài. Không kết luận SOTA.

6.1. Theo độ dài bài

Chia 100 bài thành ba nhóm gần bằng nhau theo số token thân bài (ngưỡng 300 và 500: làm tròn tertile p33 $\approx$ 298, p67 $\approx$ 492). Cùng tokenizer với bảng 1.

Bảng 1b. ROUGE-1 theo độ dài thân bài.

Nhóm	n	Lead-3	TextRank	ViT5
Ngắn (<300 từ)	34	0,2581	0,2672	0,2919
Trung (300–499)	33	0,2638	0,2409	0,2549
Dài ($\geq$ 500 từ)	33	0,2298	0,2194	0,2519

Bài ngắn: ViT5 cao nhất. Bài trung: Lead-3 cao nhất. Bài dài: cả ba giảm, ViT5 vẫn hơn extractive. TextRank không thắng nhóm nào trên R-1. Đây là quan sát trên 100 bài, không suy nguyên nhân chắc.

6.2. Extractive trên 500 bài (Lead-k và Oracle)

Cùng split test, id 000001–000500. Oracle-3 chọn tổ hợp 3 câu trong bài làm ROUGE-1 F1 với gold lớn nhất (tối đa 39 câu/bài). ViT5 trên 500 bài chưa chạy.

Bảng 1c. ROUGE F1 extractive, n=500.

Hệ	ROUGE-1	ROUGE-2	ROUGE-L
Lead-1	0,2719	0,1305	0,2092
Lead-3	0,2569	0,1294	0,1856
Lead-5	0,2256	0,1199	0,1624
TextRank-3	0,2499	0,1198	0,1815
Oracle-3	0,4646	0,2793	0,3410

Lead-1 > Lead-3 > Lead-5: gold gần câu mở đầu; lấy thêm câu làm giảm overlap n-gram. Oracle-3 $\approx$ 0,46 trong khi Lead-3 $\approx$ 0,26: extractive còn cửa, Lead-3 chưa chọn đúng câu.

7. Phân tích lỗi (20 bài đọc tay)

Đối chiếu gold với ba hệ trên 20 id rải trong test-100 (gồm 000001–000003 và các id cách đều). Chi tiết: results/error_analysis.md.

Bảng 2. Ba ví dụ ViT5 sai sự thật dù ROUGE có thể không thấp.

Id	Gold	ViT5	Lỗi
000001	Hồ Xuân Huy, 12 năm tù (Đà Nẵng).	Bùi Quang Huy / Vũ nhôm, 3,2 tỷ.	Sai tên
000011	Trộm máy ủi, bán, mua dây chuyền.	“Xe bồn”, thuê sửa chữa.	Bịa đối tượng
000036	Vinh chốt Rolex 7.000 USD.	Vinh “khai cho ông Vinh” 27 tỷ.	Gán nhầm lời Dương

Ngoài ra: 000003 ViT5 đảo polarity (“dung dịch chất lượng tốt” trong bài điều tra quảng cáo); 000031 bịa dao/súng khi gold là đốt xe; 000051 Lead-3 gần như không nêu vụ nổ micro; 000066 (bản tin 24h, nhiều tin/bài) cả ba hệ đều cắt, lặp hoặc trộn tin. Lead-3 ít bịa vì lấy câu sẵn có, nhưng hay lệch gold khi gold là kết luận phiên toà hoặc sáo. TextRank đôi khi lấy câu chú thích ảnh hoặc nhảy chuyên án.

Hệ quả cho bảo vệ: ROUGE ViT5 cao hơn không chứng minh bản tóm tắt đúng tên và số. Đọc tay là bắt buộc.

8. Demo

Ứng dụng Gradio ba cột (Lead-3 | TextRank | ViT5) trên 100 bài, kèm ROUGE từng bài. ViT5 lấy từ results/preds.json, không gọi GPU lúc demo. Chạy local: python app/demo.py. Chạy Docker: docker run --rm -p 7860:7860 vietnews-demo. Địa chỉ: http://127.0.0.1:7860.

9. Kết luận và hạn chế

Trên 100 bài test đầu Vietnews, ViT5 (checkpoint sẵn) có ROUGE cao hơn Lead-3 và TextRank một chút. Đọc tay cho thấy abstractive vẫn ảo giác. Extractive an toàn hơn về chữ, dễ lệch sáo.

Hạn chế: chỉ 100 bài, không phải toàn bộ test paper; ViT5 đã học Vietnews nên không tách được khả năng mô hình với việc đã thấy miền này; chưa đo thời gian sinh câu; chưa mở 500 bài.

Nếu làm tiếp: đếm sai tên/số có hệ thống trên nhiều bài hơn; tách các bài “an ninh 24h”; không fine-tune trùng Vietnews.

10. Tài liệu

1. Vietnews / VNDS: <https://github.com/ThanhChinhBK/vietnews>
2. Phan et al. (2022). ViT5: Pretrained Text-to-Text Transformer for Vietnamese. NAACL SRW. Checkpoint: VietAI/vit5-base-vietnews-summarization
3. Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries.

4. Mihalcea, R. & Tarau, P. TextRank.

5. Repo nhóm: <https://github.com/hoangdq08/vietnews-summarization-extractive-abstractive>

Phụ lục số liệu: results/scores.csv, results/scores_mean.txt, results/preds.json, results/error_analysis.md. Slide: slides/CS221-Vietnews-tom-tat.pptx.